

BÁO CÁO MÔ TẢ BỘ DỮ LIỆU

MOVIELENS 100K DATASET

Nguồn: GroupLens Research – Đại học Minnesota
(<https://grouplens.org/datasets/movielens/100k/>)

1. Giới thiệu chung

MovieLens 100K là một trong những bộ dữ liệu chuẩn (benchmark dataset) được sử dụng phổ biến nhất trong lĩnh vực hệ thống gợi ý (recommender systems). Bộ dữ liệu ghi lại các lượt đánh giá phim thực tế của người dùng trên nền tảng MovieLens, một dịch vụ gợi ý phim trực tuyến. Đây là phiên bản dữ liệu đầu tiên và nhỏ nhất trong họ các bộ dữ liệu MovieLens (100K, 1M, 10M, 20M, 25M...).

2. Nguồn gốc và quá trình thu thập dữ liệu

Bộ dữ liệu được thu thập và công bố bởi nhóm nghiên cứu GroupLens Research, thuộc Khoa Khoa học máy tính và Kỹ thuật, Đại học Minnesota (Hoa Kỳ). Dữ liệu được lấy trực tiếp từ website MovieLens (movielens.umn.edu) trong khoảng thời gian 7 tháng, từ ngày 19/09/1997 đến ngày 22/04/1998.

Sau khi thu thập, dữ liệu đã được làm sạch theo các tiêu chí sau:

- Chỉ giữ lại những người dùng đã đánh giá tối thiểu 20 bộ phim.
- Chỉ giữ lại những người dùng có đầy đủ thông tin nhân khẩu học (tuổi, giới tính, nghề nghiệp, mã vùng).
- Quá trình làm sạch và chuẩn hoá dữ liệu được thực hiện bởi Al Borchers, thành viên của nhóm GroupLens.

Bộ dữ liệu được công bố lần đầu vào tháng 4 năm 1998 và đến nay vẫn được duy trì như một bộ dữ liệu chuẩn ổn định (stable benchmark) phục vụ cho việc giảng dạy, kiểm thử và so sánh các thuật toán gợi ý.

3. Quy mô và đặc điểm dữ liệu

Đặc điểm	Giá trị
Số lượt đánh giá (rating)	100.000
Thang điểm đánh giá	Từ 1 đến 5 (số nguyên)
Số người dùng	943
Số bộ phim	1.682
Số lượt đánh giá tối thiểu / người dùng	20
Thông tin nhân khẩu học người dùng	Tuổi, giới tính, nghề nghiệp, mã vùng (zip code)
Thông tin định danh cá nhân	Không có
Thời gian thu thập	19/09/1997 – 22/04/1998
Ngày công bố	Tháng 4/1998

4. Cấu trúc các tệp dữ liệu

Sau khi giải nén file ml-100k.zip, dữ liệu được tổ chức thành nhiều tệp văn bản, các trường được phân tách bằng dấu tab. Bảng dưới đây tóm tắt nội dung của các tệp chính:

Tên tệp	Nội dung
u.data	Toàn bộ 100.000 lượt đánh giá, gồm các trường: mã người dùng, mã phim, điểm đánh giá, mốc thời gian (Unix timestamp). Dữ liệu được sắp xếp ngẫu nhiên.
u.info	Thống kê tổng số người dùng, số phim và số lượt đánh giá.
u.item	Thông tin về phim: mã phim, tên phim, ngày phát hành, ngày phát hành video, liên kết IMDb và 19 cờ thể loại (0/1) cho biết phim thuộc thể loại nào (một phim có thể thuộc nhiều thể loại).
u.genre	Danh sách các thể loại phim được sử dụng trong u.item.
u.user	Thông tin nhân khẩu học của người dùng: mã người dùng, tuổi, giới tính, nghề nghiệp, mã vùng.
u.occupation	Danh sách các nghề nghiệp được sử dụng trong u.user.
u1.base / u1.test ... u5.base / u5.test	Năm bộ chia train/test theo tỉ lệ 80/20, dùng cho kiểm định chéo 5-fold (5-fold cross validation).
ua.base / ua.test, ub.base / ub.test	Hai bộ chia train/test trong đó tập test có đúng 10 đánh giá cho mỗi người dùng; hai tập test này không trùng nhau.
allbut.pl, mku.sh	Các script hỗ trợ tạo lại các tập dữ liệu train/test nói trên từ tệp u.data.

5. Điều kiện sử dụng và trích dẫn

Bộ dữ liệu được công bố miễn phí cho mục đích nghiên cứu, kèm theo một số điều kiện sử dụng cơ bản:

- Người sử dụng không được tuyên bố hoặc ngụ ý rằng Đại học Minnesota hay nhóm GroupLens chứng thực cho công trình của mình.
- Phải trích dẫn nguồn dữ liệu trong các công bố khoa học có sử dụng bộ dữ liệu này.
- Không được phân phối lại dữ liệu nếu chưa có sự cho phép riêng.
- Không được sử dụng cho mục đích thương mại nếu chưa được nhóm GroupLens cho phép.

Trích dẫn đề xuất:


F. Maxwell Harper and Joseph A. Konstan. 2015. The MovieLens Datasets: History and Context. ACM Transactions on Interactive Intelligent Systems (TiiS) 5, 4, Article 19 (December 2015), 19 pages. DOI: 10.1145/2827872

Báo cáo được tổng hợp dựa trên thông tin công bố tại grouplens.org/datasets/movielens/100k/ và file README.txt kèm theo bộ dữ liệu.

Hình ảnh mô tả sơ đồ nguồn gốc của data

QUY TRÌNH TẠO TẬP DỮ LIỆU MOVIELENS 100K

(GroupLens Research – University of Minnesota)



KẾT QUẢ: TẬP DỮ LIỆU MOVIELENS 100K



943
người dùng



1.682
bộ phim



100.000
đánh giá



Thang điểm
1 – 5

Dataset này là một trong những tập dữ liệu đầu tiên và quan trọng nhất trong lĩnh vực Hệ gợi ý (Recommender Systems).