

MÔ TẢ NGUỒN GỐC CỦA DATASET

1. Giới thiệu Dataset

TMDB 5000 Movie Dataset là bộ dữ liệu chứa metadata của khoảng 5.000 bộ phim, được thu thập từ nền tảng The Movie Database (TMDB) thông qua REST API chính thức. Dataset này được publish trên Kaggle tại địa chỉ [kaggle.com/datasets/tmdb/tmdb-movie-metadata](https://www.kaggle.com/datasets/tmdb/tmdb-movie-metadata) và được sử dụng rộng rãi trong các bài toán phân tích dữ liệu, xây dựng hệ thống gợi ý phim (Recommendation System) và học máy.

Bộ dataset gồm hai file CSV chính:

- `tmdb_5000_movies.csv`: metadata phim (tiêu đề, thể loại, ngân sách, doanh thu, ngôn ngữ, từ khoá, ngày phát hành, điểm đánh giá, v.v.)
- `tmdb_5000_credits.csv`: thông tin diễn viên (cast) và đoàn phim (crew) dạng JSON stringified

2. Nguồn gốc & Chuỗi thu thập dữ liệu

Dữ liệu có nguồn gốc từ cộng đồng người dùng toàn cầu đóng góp lên nền tảng [themoviedb.org](https://www.themoviedb.org) từ năm 2008. TMDB cung cấp REST API v3 miễn phí cho mục đích phi thương mại (với điều kiện ghi nhận nguồn), cho phép truy cập toàn bộ metadata phim, diễn viên, đoàn phim và từ khoá.

Chuỗi nguồn gốc tóm tắt:

Cộng đồng người dùng → TMDB Platform → TMDB REST API → Python Script → CSV → Kaggle Dataset

Lưu ý quan trọng: phiên bản gốc của dataset này từng dựa trên dữ liệu IMDB và đã bị xoá khỏi Kaggle theo yêu cầu gỡ xuống DMCA từ IMDB. Dataset hiện tại là phiên bản thay thế, sử dụng dữ liệu từ TMDB theo đúng điều khoản sử dụng của TMDB. Do dữ liệu được cộng đồng điền thủ công, một số trường như keywords, genres và ratings có thể không nhất quán giữa các bản ghi.