

BÁO CÁO Ý TƯỞNG MERGE DATASET

MovieLens 100K × IMDb / TMDb

Tóm tắt quy trình xây dựng dataset hợp nhất phục vụ nghiên cứu các yếu tố ảnh hưởng đến nhu cầu xem phim của người dùng

1. Mục tiêu & Tổng quan

Notebook data_analysis.ipynb thực hiện việc hợp nhất hai nguồn dữ liệu phim độc lập thành một dataset duy nhất:

- MovieLens 100K — cung cấp dữ liệu hành vi: lượt đánh giá (rating) của người dùng cho từng phim, cùng hồ sơ người dùng (tuổi, giới tính, nghề nghiệp...).
- IMDb / TMDb (đã chuẩn hóa ở bước trước) — cung cấp metadata phong phú về phim: đoàn làm phim, nhà sản xuất, từ khóa nội dung.

Mục tiêu cuối cùng: tạo ra một bảng phim hợp nhất, trong đó mỗi bộ phim vừa có nhãn thể loại / lượt đánh giá từ MovieLens, vừa có metadata mở rộng từ IMDb — làm nền tảng để phân tích những yếu tố (thể loại, từ khóa, diễn viên, nhà sản xuất...) ảnh hưởng đến nhu cầu xem phim của người dùng.

Thử thách chính: hai dataset không chia sẻ chung một mã định danh phim (MovieLens dùng movie_id_ml, IMDb dùng movie_id riêng) → phải ghép nối gián tiếp thông qua tên phim (title) và năm phát hành (release), sau khi đã chuẩn hóa cả hai về cùng một định dạng.

2. Nguồn dữ liệu đầu vào

Nguồn	File	Nội dung chính
MovieLens 100K	u.data	df_ratings user_id, movie_id_ml, rating, rating_timestamp
MovieLens 100K	u.item	df_ML_movies movie_id_ml, title, release, 19 cột thể loại (genres)
MovieLens 100K	u.user	df_users user_id, user_age, user_gender, user_occupation, user_zipcode
IMDb/TMDb	title.csv	df_IMDb_movies movie_id, title, release, movie_kind...
IMDb/TMDb	cast_info.csv name.csv role_type.csv	Thông tin đoàn làm phim: diễn viên, đạo diễn, biên kịch... gắn với từng movie_id
IMDb/TMDb	keyword.csv movie_keywords.csv	Từ khóa mô tả nội dung phim, gắn với từng movie_id
IMDb/TMDb	company_name.csv movie_companies.csv	Thông tin công ty sản xuất, gắn với từng movie_id

3. Sơ đồ Workflow tổng quan

Toàn bộ quy trình gồm 6 bước chính, từ việc đọc dữ liệu thô đến khi xuất ra các bảng dữ liệu sẵn sàng cho phân tích:

QUY TRÌNH MERGE: MOVIELENS 100K ➤ IMDb / TMDB

Xây dựng dataset hợp nhất phục vụ phân tích các yếu tố ảnh hưởng đến nhu cầu xem phim của người dùng

1 NGUỒN DỮ LIỆU ĐẦU VÀO

MovieLens 100K (dữ liệu thô)

- u.data → df_ratings
- user_id, movie_id_ml, rating, rating_timestamp
- u.item → df_ML_movies
- movie_id_ml, title, release + 19 cột thể loại (genres)
- u.user → df_users
- user_id, user_age, user_gender, user_occupation, user_zipcode
- df_ratings & df_users đi thẳng tới Bước 6, không qua merge

IMDb / TMDB đã chuẩn hóa (output*.csv)

- title.csv → df_IMDb_movies
- movie_id, title, release, movie_kind ...
- cast_info.csv + name.csv + role_type.csv
- ➔ đoàn làm phim (diễn viên, đạo diễn, biên kịch ...)
- keyword.csv + movie_keywords.csv → từ khóa phim
- company_name.csv + movie_companies.csv → nhà sản xuất

2 LÀM SẠCH & CHUẨN HÓA TIÊU ĐỀ PHIM

Chuẩn hóa df_ML_movies

clean_movie_title(): bỏ năm phát hành – VD "Toy Story (1995)" → "toy story"
Đổi vị trí mao từ: "Saint, The" → "The Saint", rồi viết thường toàn bộ
Tách phim dạng "Seven (Se7en)" thành dòng tiêu đề mới trong dấu ()

Chuẩn hóa df_IMDb_movies

Áp dụng cùng hàm clean_movie_title() – đảm bảo 2 bên cùng format
Trích năm phát hành từ cột release (tách theo dấu "/")
Loại cột thừa: imdb_idx, phonetic, md5, episode_id, season, series_years ...

3 GHÉP NỐI CHÍNH (KEY JOIN) — TRỌNG TÂM CỦA QUY TRÌNH

🔗 **pd.merge(df_ML_movies, df_IMDb_movies, on=['title', 'release'])**
→ df_movies : ánh xạ movie_id_ml (MovieLens) ↔ movie_id (IMDb/TMDB) cho cùng 1 bộ phim
→ movie_ids : danh sách movie_id (IMDb) hợp lệ – dùng để LOC toàn bộ bảng IMDb con ở Bước 4
Đây là "cầu nối" duy nhất giữa 2 hệ dữ liệu – chỉ những phim trùng (title, release) mới được giữ lại

4 BỔ SUNG METADATA THEO movie_ids (LEFT JOIN + GROUPBY)

Từ khóa phim

movie_keywords x keyword
(on keyword_id)
Lọc: movie_id ∈ movie_ids
groupby(movie_id)['keyword']
.apply(list)
→ df_movie_keyword
[movie_id, keyword]

Đoàn làm phim (Cast & Crew)

cast_info x name (person_id)
x role_type (role_id)
Lọc: movie_id ∈ movie_ids
LEFT JOIN – groupby(movie_id)
→ JSON list các bản ghi
{person_id, cast_name, gender, role}
→ df_movie_cast [movie_id, cast]

Nhà sản xuất

movie_companies x company_name
(on company_id)
Lọc: movie_id ∈ movie_ids
LEFT JOIN – groupby(movie_id)
→ JSON list các bản ghi
{company_id, name, country}
→ df_movie_company [movie_id, company]

5 GỘP THÀNH BẢNG PHIM HỢP NHẤT

★ **df = df_movies x df_movie_keyword x df_movie_cast x df_movie_company (on movie_id)**
Mỗi dòng = 1 bộ phim, kèm đầy đủ: thể loại MovieLens, từ khóa, đoàn làm phim, nhà sản xuất từ IMDb/TMDB
→ Lưu thành **data/movies_cast_company.csv** – bảng "xương sống" cho phân tích yếu tố ảnh hưởng đến nhu cầu xem phim

6 KẾT QUẢ ĐẦU RA (thư mục data/)

movies_cast_company.csv

Bảng tổng hợp đầy đủ.
Input chính cho phân tích các yếu tố ảnh hưởng đến nhu cầu xem phim của người dùng.

movies.csv, cast.csv, companies.csv

Các bảng module được tách riêng theo từng nhóm thông tin (phim / đoàn làm phim / nhà sản xuất).

ratings.csv, users.csv

Hành vi đánh giá & hồ sơ người dùng – giữ nguyên từ MovieLens, KHÔNG đi qua bước merge phim.

*_report.html

Báo cáo EDA tự động (ydata-profiling) cho movies / cast / companies / ratings / users – hỗ trợ kiểm tra chất lượng dữ liệu.

4. Các bước xử lý chính

4.1. Làm sạch & chuẩn hóa tiêu đề phim

Vì phép ghép nối chính dựa trên tên phim (title), cả hai bảng `df_ML_movies` và `df_IMDb_movies` đều được đưa qua cùng một hàm `clean_movie_title()` để đảm bảo định dạng nhất quán:

- Loại bỏ năm phát hành khỏi tiêu đề — ví dụ “Toy Story (1995)” → “toy story”.
- Đổi vị trí mạo từ đứng cuối — ví dụ “Saint, The” → “The Saint”.
- Chuyển toàn bộ tiêu đề về chữ thường (lowercase) để so khớp không phân biệt hoa/thường.
- Xử lý riêng các phim có tên thay thế trong dấu ngoặc (ví dụ “Seven (Se7en)”) bằng cách tạo thêm một dòng mới với tên trong ngoặc, giúp tăng khả năng khớp ở cả hai cách viết.

Đối với `df_IMDb_movies`, năm phát hành (release) được trích từ cột ngày đầy đủ (dạng YYYY/MM/DD), và các cột không cần thiết cho việc merge (`imdb_idx`, `phonetic`, `md5`, `episode_id`, `season`, `episode`, `series_years`) được loại bỏ.

4.2. Ghép nối chính — Key Join (`df_movies`)

```
df_movies = pd.merge(df_ML_movies, df_IMDb_movies, on=["title", "release"])
```

Đây là bước trung tâm của toàn bộ pipeline:

- Tạo cầu nối giữa hai hệ định danh khác nhau: `movie_id_ml` (MovieLens) ↔ `movie_id` (IMDb/TMDB) cho cùng một bộ phim.
- Sinh ra `movie_ids` — danh sách các `movie_id` (IMDb) hợp lệ sau khi ghép, được dùng làm bộ lọc cho tất cả các bảng IMDb phụ ở bước tiếp theo.
- Vì là inner join với điều kiện khớp tuyệt đối (title, release), chỉ những phim có tiêu đề và năm phát hành trùng khớp ở cả hai nguồn mới được giữ lại — đây là điểm quyết định số lượng phim cuối cùng trong dataset hợp nhất.

4.3. Bổ sung metadata theo `movie_ids`

Ba nhóm thông tin từ IMDb/TMDB được xử lý song song theo cùng một khuôn mẫu: lọc theo `movie_ids` → ghép nối (left join) với bảng tham chiếu → gom nhóm (groupby) theo `movie_id`.

a) Từ khóa phim → `df_movie_keyword`

```
movie_keywords ⋈ keyword (on keyword_id) →  
groupby(movie_id)["keyword"].apply(list)
```

Kết quả: mỗi phim có một danh sách (list) các từ khóa mô tả nội dung.

b) Đoàn làm phim → `df_movie_cast`

```
cast_info ⋈ name (person_id) ⋈ role_type (role_id), left join →  
groupby(movie_id)
```

Thông tin của từng diễn viên/thành viên đoàn phim (`person_id`, `cast_name`, `cast_gender`, vai trò) được nén thành một chuỗi JSON cho mỗi phim, giữ được quan hệ một-nhiều (1 phim — nhiều người) trong một cột duy nhất.

c) Nhà sản xuất → `df_movie_company`

```
movie_companies ⋈ company_name (on company_id), left join → groupby(movie_id)
```

Tương tự, thông tin các công ty sản xuất (company_id, name, country) liên quan đến mỗi phim được nén thành chuỗi JSON.

4.4. Gộp thành bảng phim hợp nhất (df)

```
df = df_movies ⋈ df_movie_keyword ⋈ df_movie_cast ⋈ df_movie_company (on  
movie_id)
```

Kết quả cuối cùng là một bảng duy nhất, trong đó mỗi dòng tương ứng với một bộ phim, bao gồm: thông tin gốc + thể loại từ MovieLens, năm phát hành/metadata từ IMDb, danh sách từ khóa, danh sách đoàn làm phim (JSON) và danh sách nhà sản xuất (JSON). Bảng này được lưu thành data/movies_cast_company.csv — đóng vai trò “xương sống” cho các bước phân tích tiếp theo.

5. Kết quả đầu ra (thư mục data/)

File	Nội dung	Mục đích sử dụng
movies_cast_company.csv	Bảng phim hợp nhất đầy đủ (thể loại, từ khóa, cast, công ty sản xuất), cầu nối tham chiếu 2 hệ id	Input chính cho phân tích đa yếu tố ảnh hưởng đến nhu cầu xem phim
movies.csv cast.csv companies.csv	Các bảng module được tách riêng theo từng nhóm thông tin	Tra cứu / phân tích nhanh theo từng chủ đề (phim, đoàn phim, nhà sản xuất)
ratings.csv users.csv	Lượt đánh giá và hồ sơ người dùng — giữ nguyên từ MovieLens, không qua bước merge phim	Phân tích hành vi người dùng, xây dựng mô hình gợi ý (recommendation)
*_report.html	Báo cáo EDA tự động (ydata-profiling) cho từng bảng	Kiểm tra chất lượng, phân phối và giá trị thiếu của dữ liệu