

BÁO CÁO

Cào Dữ Liệu Phim Từ TMDB API

Môn học: DBI202 – Cơ sở dữ liệu

Ngày báo cáo: 20/06/2026

1. Tổng Quan

Mục tiêu của phần cào dữ liệu là thu thập và mở rộng bộ dữ liệu phim từ nguồn The Movie Database (TMDB), kết hợp với bộ dữ liệu MovieLens 100K, nhằm cung cấp đầy đủ dữ liệu cho hệ thống cơ sở dữ liệu phim theo sơ đồ ERD gồm 11 bảng.

Lý do cần cào thêm dữ liệu

- Bộ dữ liệu gốc (tmdb_5000_movies.csv và tmdb_5000_credits.csv) chỉ chứa khoảng 4.803 phim, dữ liệu cũ dừng ở khoảng năm 2017.
- Cần bổ sung phim mới (2017–2026) để dataset phong phú và cập nhật hơn.
- Dữ liệu gốc ở dạng thô (chứa chuỗi JSON lồng nhau), cần bóc tách và chuẩn hóa theo ERD.

2. Nguồn Dữ Liệu

Nguồn	Mô tả	File gốc
TMDB 5000 Dataset	~4.803 phim với metadata đầy đủ (thể loại, công ty sản xuất, từ khóa, cast, crew)	tmdb_5000_movies.csv (6.4 MB) tmdb_5000_credits.csv (56 MB)
TMDB API v3	API chính thức để cào thêm phim mới	api.themoviedb.org/3
MovieLens 100K	100.000 lượt đánh giá từ 943 người dùng	ml-100k/u.user ml-100k/u.data

Cấu hình API Key

- API Key được lưu trong file `.env` với biến `TMDB_API_KEY`.
- Key được đăng ký tại: <https://www.themoviedb.org/settings/api>

3. Các Script Đã Xây Dựng

3.1. fetch_more_tmdb.py — Cào phim mới (Script phiên bản 1)

Mục đích: Cào thêm phim mới từ TMDB API để bổ sung vào 2 file CSV gốc, giữ nguyên cấu trúc cột.

Quy trình hoạt động:

Bước 1: Đọc dataset hiện có (tmdb_5000_movies.csv)
→ Xác định movie_id đã có để lọc trùng

Bước 2: Gọi /discover/movie API
 → Lấy danh sách movie_id mới (2017-2026)
 → Sắp xếp theo ngày phát hành mới nhất

Bước 3: Với mỗi phim mới:
 → Gọi /movie/{id}?append_to_response=keywords
 → Gọi /movie/{id}/credits
 → Thu thập metadata + cast/crew

Bước 4: Gộp dữ liệu mới với dữ liệu cũ
 → Lưu lại vào tmdb_5000_movies.csv
 → Lưu lại vào tmdb_5000_credits.csv

Cách chạy:

```
pip install requests pandas python-dotenv
python fetch_more_tmdb.py --pages 20 --start_year 2017 --end_year 2026
```

Tham số:

Tham số	Mặc định	Mô tả
--pages	10	Số trang discover (mỗi trang ~20 phim)
--start_year	2017	Năm bắt đầu lấy phim
--end_year	2026	Năm kết thúc
--movies_csv	tmdb_5000_movies.csv	File movies đầu vào
--credits_csv	tmdb_5000_credits.csv	File credits đầu vào

3.2. fetch_erd_data.py — Cào + Chuyển đổi theo ERD (Script phiên bản 2 – Hoàn chỉnh)

Mục đích: Kết hợp cào dữ liệu mới VÀ chuyển đổi toàn bộ thành 11 file CSV theo đúng sơ đồ ERD, sẵn sàng import vào SQL Server.

Quy trình hoạt động (5 bước):

```
[1/5] Đọc tmdb_5000_movies.csv (dữ liệu cũ)
↓
[2/5] Đọc tmdb_5000_credits.csv (dữ liệu cũ)
↓
[3/5] Discover phim mới từ TMDB API (2017-2026)
→ Gọi /discover/movie với bộ lọc:
  • sort_by: popularity.desc
  • vote_count.gte: 50 (chỉ lấy phim có đủ vote)
  • include_adult: false
↓
[4/5] Lấy chi tiết từng phim mới:
→ /movie/{id}?append_to_response=keywords
→ /movie/{id}/credits
↓
[5/5] Transform + Xuất 11 file CSV theo ERD
```

11 bảng CSV đầu ra:

#	Bảng	Mô tả	Cột
1	MOVIE.csv	Thông tin phim	movie_id, title, url, release
2	CAST.csv	Diễn viên & nhân viên đoàn	cast_id, cast_name, cast_gender
3	CAST_MOVIE.csv	Liên kết Cast ↔ Movie	cast_id, movie_id, cast_role
4	GENRE.csv	Thể loại phim	gender_id, gender_name
5	MOVIE_GENRE.csv	Liên kết Movie ↔ Genre	movie_id, genre_id
6	COMPANIES.csv	Công ty sản xuất	company_id, company_name
7	COMPANIES_MOVIE.csv	Liên kết Company ↔ Movie	company_id, movie_id
8	KEYWORD.csv	Từ khóa phim	keyword_id, keyword
9	MOVIE_KEYWORD.csv	Liên kết Movie ↔ Keyword	movie_id, keyword_id
10	USERS.csv	Người dùng (từ MovieLens)	user_id, user_age, user_gender, user_occupation, user_zipcode
11	RATINGS.csv	Đánh giá phim	user_id, movie_id, rating, rating_timestamp

Cách chạy:

```
python fetch_erd_data.py --pages 15 --start_year 2017 --end_year 2026
```

4. Kỹ Thuật Xử Lý Trong Quá Trình Cào

4.1. Xử lý Rate-Limit (HTTP 429)

TMDB API giới hạn số request. Script tự động xử lý:

```
if r.status_code == 429:
    wait = int(r.headers.get("Retry-After", 3))
    time.sleep(wait + 1) # Đợi theo header Retry-After
    continue # Thử lại request
```

4.2. Xử lý lỗi mạng (Retry với Exponential Backoff)

Script retry tối đa 5 lần khi gặp lỗi mạng, với thời gian chờ tăng dần:

```
# fetch_erd_data.py: 3s, 6s, 9s, 12s, 15s
wait = 3 * (attempt + 1)

# fetch_more_tmdb.py: 1s, 2s, 4s, 8s, 16s (exponential)
wait = 2 ** attempt
```

Các loại lỗi được xử lý:

- `ConnectionError` — Mất kết nối mạng
- `Timeout` — Request vượt quá thời gian chờ (15–20s)

- `ChunkedEncodingError` — Lỗi truyền dữ liệu
- `ConnectionResetError` — Server ngắt kết nối

4.3. Loại trùng lặp (Deduplication)

- So sánh `movie_id` từ API với tập `existing_ids` đã có trong file CSV cũ.
- Chỉ fetch chi tiết những phim chưa có trong dataset.
- Sử dụng `dict.fromkeys()` để loại trùng ID trong danh sách discover.

4.4. Parse dữ liệu JSON lồng nhau

Dữ liệu gốc chứa chuỗi JSON trong các cột CSV (ví dụ genres, cast, crew). Hàm `safe_parse()` xử lý linh hoạt:

```
def safe_parse(val):
    """Parse JSON/Python-literal string; trả [] nếu lỗi."""
    if pd.isna(val): return []
    try:
        return json.loads(val)      # Thử JSON trước
    except:
        return ast.literal_eval(val) # Fallback sang Python literal
```

4.5. Tối ưu gọi API (`append_to_response`)

Gộp request lấy chi tiết phim + keywords trong 1 lần gọi thay vì 2:

```
tmdb_get(f"/movie/{movie_id}", {
    "append_to_response": "keywords" # Gộp keywords vào response
})
```

KẾT QUẢ

Giảm 50% số request cho phần metadata phim.

4.6. Throttle — Kiểm soát tốc độ gọi API

```
time.sleep(0.3) # fetch_erd_data.py: 300ms giữa mỗi phim
time.sleep(0.25) # fetch_more_tmdb.py: 250ms giữa mỗi phim
time.sleep(0.15) # Discover: 150ms giữa mỗi trang
```

5. Kết Quả Đạt Được

Dữ liệu sau khi cào và xử lý:

Bảng	Số dòng	Ghi chú
MOVIE	5.301	4.803 cũ + ~300 phim mới (2017–2026)
CAST	133.092	Diễn viên + nhân viên đoàn phim
CAST_MOVIE	278.060	Liên kết vai diễn / công việc
GENRE	20	20 thể loại phim
MOVIE_GENRE	13.387	Liên kết thể loại – phim
COMPANIES	5.682	Công ty sản xuất phim
COMPANIES_MOVIE	14.932	Liên kết công ty – phim
KEYWORD	11.169	Từ khóa mô tả nội dung phim
MOVIE_KEYWORD	40.729	Liên kết từ khóa – phim
USERS	943	Người dùng từ MovieLens 100K
RATINGS	100.000	Lượt đánh giá (thang 1–5 sao)

Tổng dung lượng file output:

Thư mục	Mô tả	Dung lượng
Assignment/output_erd/	11 file CSV chuẩn ERD	~14.8 MB
tmdb_5000_movies.csv	File gốc đã gộp phim mới	~6.4 MB
tmdb_5000_credits.csv	File credits đã gộp	~56 MB

6. Các Endpoint TMDB API Đã Sử Dụng

Endpoint	Mục đích	Tham số chính
GET /discover/movie	Lấy danh sách phim theo bộ lọc	sort_by, primary_release_date.gte/lte, vote_count.gte, page
GET /movie/{id}	Lấy chi tiết phim	append_to_response=keywords
GET /movie/{id}/credits	Lấy danh sách cast + crew	—

7. Tóm Tắt Công Việc Đã Hoàn Thành

#	Công việc	Trạng thái
1	Đăng ký & cấu hình TMDB API Key	✓ Hoàn thành
2	Viết script fetch_more_tmdb.py (cào phim bổ sung vào CSV gốc)	✓ Hoàn thành
3	Viết script fetch_erd_data.py (cào + transform theo ERD)	✓ Hoàn thành

#	Công việc	Trạng thái
4	Cào thêm ~300 phim mới (2017–2026) từ TMDB API	✓ Hoàn thành
5	Xử lý rate-limit, lỗi mạng, retry tự động	✓ Hoàn thành
6	Parse JSON lồng nhau từ dữ liệu gốc	✓ Hoàn thành
7	Bóc tách & chuẩn hóa thành 11 bảng theo ERD	✓ Hoàn thành
8	Tích hợp dữ liệu MovieLens 100K (Users + Ratings)	✓ Hoàn thành
9	Xuất 11 file CSV sẵn sàng import SQL Server	✓ Hoàn thành
10	Viết script SQL import (BULK INSERT + xử lý trùng lặp)	✓ Hoàn thành

Báo cáo được tạo tự động ngày 20/06/2026 | DBI202 — Cơ sở dữ liệu