

SƠ ĐỒ CHUẨN HOÁ DỮ LIỆU

TMDB 5000 Movie Dataset

Script: [DBI202/dataset_transform.py at main · ngoquangtrai1903-source/DBI202](#) | 2 CSV gốc → 8 bảng chuẩn hoá

1. Tổng quan quy trình chuẩn hoá

Script `transform_tmdb.py` thực hiện chuẩn hoá dữ liệu từ 2 file CSV gốc của Kaggle TMDB 5000 thành 8 bảng quan hệ theo mô hình Star Schema, gồm 5 bảng chiều (dimension) và 3 bảng sự kiện / junction (fact). Quá trình bao gồm 5 bước chính:

- Bước 1 — Đọc dữ liệu: `pd.read_csv()` với xử lý lỗi dòng xấu
- Bước 2 — Parse JSON: `safe_parse()` dùng `json.loads()` → `ast.literal_eval()`
- Bước 3 — Tạo bảng chiều (dimension tables): tên người, phim, từ khoá, hãng, vai trò
- Bước 4 — Tạo bảng sự kiện (fact/junction tables): quan hệ nhiều-nhiều giữa các thực thể
- Bước 5 — Xuất CSV: utf-8-sig để hiển thị đúng tiếng Việt

2. Các bước xử lý trong script

Bước	Tên bước	Hàm / Kỹ thuật	Đầu ra
1	Đọc dữ liệu gốc	<code>pd.read_csv()</code> — <code>dtype=str</code> , <code>escapechar</code> , <code>on_bad_lines='skip'</code>	<code>movies_raw</code> DataFrame · <code>credits_raw</code> DataFrame
2	Parse JSON columns	<code>safe_parse()</code> — <code>json.loads()</code> → <code>ast.literal_eval()</code> fallback	Python list từ chuỗi JSON: <code>genres</code> , <code>cast</code> , <code>crew</code> , <code>keywords</code> , <code>companies</code>
3	Sinh Dimension Tables	<code>soundex()</code> · <code>md5hex()</code> · <code>safe_int()</code> · <code>add_person()</code> · <code>registry dict</code>	<code>title.csv</code> · <code>name.csv</code> · <code>role_type.csv</code> · <code>keyword.csv</code> · <code>company_name.csv</code>
4	Sinh Fact / Junction Tables	Loop qua từng <code>movie_id</code> , dedup bằng set seen, tăng dần auto ID	<code>cast_info.csv</code> · <code>movie_keywords.csv</code> · <code>movie_companies.csv</code>
5	Xuất CSV	<code>df.to_csv(encoding='utf-8-sig', index=False)</code>	8 file CSV trong thư mục <code>output/</code>

3. Bảng chiều (Dimension Tables)

Dimension tables lưu trữ thông tin tham chiếu — mỗi thực thể có Primary Key duy nhất. Các kỹ thuật bổ sung gồm `soundex()` cho tìm kiếm theo âm thanh và `md5hex()` làm fingerprint kiểm tra trùng lặp.

Bảng	Primary Key	Các cột chính	Nguồn gốc trong script
<code>title.csv</code>	<code>movie_id</code>	<code>title</code> , <code>imdb_idx</code> , <code>movie_kind</code> , <code>release</code> , <code>phonetic (soundex)</code> , <code>md5</code>	<code>movies_raw[id]</code> · <code>soundex(title)</code> · <code>md5hex(title)</code>

Bảng	Primary Key	Các cột chính	Nguồn gốc trong script
name.csv	<i>person_id</i>	cast_name, imdb_idx, cast_gender, name_cf, name_nf, surname, md5	<i>credits_raw[cast] & [crew] · add_person()</i>
role_type.csv	<i>role_id</i>	cast_role (actor / Director / Producer...)	<i>Tập hợp job từ credits_raw[crew]</i>
keyword.csv	<i>keyword_id</i>	keyword, phonetic (soundex)	<i>movies_raw[keywords] · kw_registry</i>
company_name.csv	<i>company_id</i>	name, country, name_nf, name_sf (soundex), md5	<i>movies_raw[production_companies] · co_registry</i>

4. Bảng sự kiện / Junction (Fact Tables)

Fact tables thể hiện quan hệ nhiều-nhiều giữa các thực thể. Mỗi bảng chứa auto-increment ID riêng và các khoá ngoại (FK) trở về bảng chiều. Dedup được thực hiện bằng set seen để tránh bản ghi trùng trong cùng một phim.


Bảng	PK	Foreign Keys	Các cột bổ sung
cast_info.csv	<i>cast_id</i>	person_id → name movie_id → title role_id → role_type	note (character / department), nr_order, person_role_id
movie_keywords.csv	<i>mkid</i>	movie_id → title keyword_id → keyword	— (bảng junction thuần)
movie_companies.csv	<i>mcid</i>	movie_id → title company_id → company_name	ctype (production), note

5. Danh sách quan hệ khoá ngoại (FK Relationships)

Bảng con (Fact)	Cột FK	Bảng cha (Dim)	Ý nghĩa quan hệ
cast_info.csv	person_id	name.csv	Người trong cast/crew thuộc bảng người
cast_info.csv	movie_id	title.csv	Diễn viên/đoàn phim thuộc về phim nào
cast_info.csv	role_id	role_type.csv	Vai trò: actor / Director / Producer...
movie_keywords.csv	movie_id	title.csv	Từ khoá gắn với phim nào
movie_keywords.csv	keyword_id	keyword.csv	Chi tiết từ khoá (tên, phonetic)
movie_companies.csv	movie_id	title.csv	Hãng sản xuất thuộc về phim nào
movie_companies.csv	company_id	company_name.csv	Chi tiết hãng (tên, quốc gia)

6. Sơ đồ luồng chuẩn hoá dữ liệu

Sơ đồ dưới đây mô tả toàn bộ luồng từ 2 CSV gốc qua hàm transform() đến 8 bảng đầu ra:



7. Các hàm kỹ thuật hỗ trợ

7.1. `safe_parse(val)`

Parse chuỗi JSON hoặc Python literal. Thử `json.loads()` trước, nếu thất bại thử `ast.literal_eval()`. Trả về `[]` nếu giá trị null hoặc rỗng. Dùng để mở JSON stringified trong các cột `genres`, `cast`, `crew`, `keywords`, `production_companies`.

7.2. `soundex(name)`

Thuật toán Soundex cổ điển — mã hoá tên thành 4 ký tự theo âm thanh (ví dụ: 'Robert' → 'R163'). Dùng cho trường phonetic trong `title.csv` và `keyword.csv` để hỗ trợ tìm kiếm tên gần âm.

7.3. `md5hex(s)`

Băm chuỗi bằng MD5, trả về chuỗi hex 32 ký tự. Dùng làm fingerprint kiểm tra trùng lặp dữ liệu trong `title.csv`, `name.csv` và `company_name.csv`.

7.4. `safe_int(val)`

Chuyển đổi an toàn sang kiểu `int`, trả về `None` thay vì `raise exception` nếu thất bại. Dùng để validate `movie_id`, `person_id`, `keyword_id`, `company_id` trước khi xử lý.

Dataset: kaggle.com/datasets/tmdb/tmdb-movie-metadata | Script: [DBI202/dataset_transform.py at main · ngoquangtrai1903-source/DBI202](#) | Output: 8 CSV files