

BÁO CÁO KỸ THUẬT

Workflow Thu thập & Xử lý Dữ liệu Phim

Tích hợp dữ liệu bổ sung từ TMDB API vào Dataset gốc (DBI202)

Người thực hiện: Nguyễn Thị Kiều My, Ngô Quang Trãi

Ngày lập báo cáo: 21 Tháng 6, 2026

Mục lục

Mục lục	2
1. Bối cảnh và Mục tiêu Dự án	3
2. Tổng quan Quy trình (Pipeline Overview).....	3
3. Chi tiết Logic Xử lý từng Bước.....	4
3.1. Bước 1 — Scrape Data	4
3.2. Bước 2 — Chuẩn hoá ban đầu (dataset_transform.py)	4
3.3. Bước 3 — Lọc và Hợp nhất (normalize.py)	5
3.4. Bước 4 — Làm giàu dữ liệu / Cập nhật chỉ số (add_rating.py)	6
4. Kết luận.....	7

1. Bối cảnh và Mục tiêu Dự án

Dataset gốc của dự án được xây dựng theo mô hình quan hệ chuẩn hoá (gồm các bảng movies, cast, companies, keyword, genre...). Theo thời gian, dữ liệu phim mới liên tục xuất hiện trên thị trường, khiến dataset gốc bị lạc hậu so với thực tế.

Mục tiêu của workflow này là xây dựng một quy trình tự động, có thể tái sử dụng để:

- Thu thập (scrape) dữ liệu phim mới từ nguồn dữ liệu mở TMDB API.
- Chuẩn hoá dữ liệu thô về cùng cấu trúc bảng với dataset gốc (cùng tên cột, cùng kiểu khoá chính/khoá ngoại).
- Làm sạch, loại bỏ trùng lặp và hợp nhất (merge) dữ liệu mới vào dataset gốc.
- Làm giàu thêm các chỉ số đánh giá (rating) để phục vụ phân tích và truy vấn sau này.

Kết quả mong đợi

Một dataset duy nhất, cập nhật (up-to-date), không trùng lặp dữ liệu, đảm bảo tính nhất quán về khoá chính/khoá ngoại giữa các bảng, sẵn sàng phục vụ cho hệ thống cơ sở dữ liệu phim (DBI202).

2. Tổng quan Quy trình (Pipeline Overview)

Toàn bộ pipeline gồm 4 bước tuần tự, mỗi bước nhận đầu vào là kết quả của bước trước và tạo ra đầu ra cho bước sau. Đây là mô hình xử lý dữ liệu dạng ETL (Extract – Transform – Load) mở rộng, có thêm bước làm giàu dữ liệu (Enrichment) ở cuối.

SCRAPE → TRANSFORM → NORMALIZE & MERGE → ENRICH

Bước	File / Công cụ	Vai trò trong pipeline
1	TMDB API	Thu thập dữ liệu phim mới (thông tin phim, diễn viên, đoàn làm phim) trực tiếp từ nguồn.
2	dataset_transform.py	Chuyển dữ liệu thô (JSON lồng nhau) thành 8 bảng quan hệ chuẩn hoá, tương ứng cấu trúc dataset gốc.
3	normalize.py	Lọc cột dư thừa, gộp (concat) dữ liệu mới vào dataset gốc, loại bỏ trùng lặp, đồng bộ ID.
4	add_rating.py	Bổ sung chỉ số vote_average và vote_count vào bảng movies bằng phép join.

3. Chi tiết Logic Xử lý từng Bước

3.1. Bước 1 — Scrape Data

BƯỚC 1 · Thu thập dữ liệu thô từ TMDB API
File thực thi: <i>(Script scraping – không có trong phạm vi code đính kèm)</i>
Mục tiêu ▶ Lấy về dữ liệu phim mới nhất chưa tồn tại trong dataset gốc, dưới dạng thô (raw), bao gồm thông tin phim và đoàn làm phim.
Đầu vào ▶ TMDB API (The Movie Database)
Xử lý chính ▶ Gọi API để lấy thông tin phim: tiêu đề, ngày phát hành, từ khoá (keywords), công ty sản xuất... ▶ Gọi API để lấy thông tin nhân sự: danh sách diễn viên (cast) và đoàn làm phim (crew).
Đầu ra ▶ tmdb_5000_movies.csv — dữ liệu phim dạng thô, các trường JSON dạng chuỗi (genres, keywords, production_companies...). ▶ tmdb_5000_credits.csv — dữ liệu cast/crew dạng thô, tương tự cấu trúc Kaggle TMDB 5000.

3.2. Bước 2 — Chuẩn hoá ban đầu (dataset_transform.py)

Đây là bước quan trọng nhất về mặt kỹ thuật: chuyển 2 file CSV thô (chứa các cột JSON lồng nhau) thành 8 bảng quan hệ phẳng, đúng chuẩn của một cơ sở dữ liệu quan hệ.

BƯỚC 2 · Transform dữ liệu thô → 8 bảng chuẩn hoá
File thực thi: <i>dataset_transform.py</i>
Mục tiêu ▶ Parse các trường JSON lồng nhau (cast, crew, keywords, production_companies) và tách thành các bảng quan hệ độc lập, có khoá chính/khoá ngoại rõ ràng.
Đầu vào ▶ tmdb_5000_movies.csv (thông tin phim) ▶ tmdb_5000_credits.csv (cast & crew)
Xử lý chính

- ▶ `safe_parse()`: parse an toàn chuỗi JSON/Python-literal, trả về danh sách rỗng nếu lỗi format, tránh crash toàn bộ pipeline.
- ▶ Sinh `role_type.csv`: thu thập toàn bộ giá trị 'job' duy nhất trong cột `crew`, gán `role_id`; vai 'actor' luôn được thêm cố định cho diễn viên.
- ▶ Sinh `name.csv`: gom toàn bộ người (cast + crew) theo `person_id`, loại trùng, tính thêm các trường phái sinh: `imdb_idx` (mã định danh dạng nmXXXXXXX), `name_cf` (tên viết hoa), `name_nf` (Họ, Tên), mã Soundex ngữ âm và mã băm MD5.
- ▶ Sinh `title.csv`: chuẩn hoá thông tin phim, sinh `imdb_idx` (ttXXXXXXX), cắt ngày phát hành về dạng YYYY-MM-DD, tính mã Soundex cho tên phim để hỗ trợ tìm kiếm gần đúng.
- ▶ Sinh `keyword.csv` & `movie_keywords.csv`: trích xuất từ khoá từ cột `keywords`, loại trùng theo cặp (`movie_id`, `keyword_id`).
- ▶ Sinh `company_name.csv` & `movie_companies.csv`: tương tự, trích xuất công ty sản xuất từ `production_companies`.
- ▶ Sinh `cast_info.csv`: với mỗi phim hợp lệ (đã có trong `title.csv`), ghép danh sách cast (vai diễn, thứ tự xuất hiện) và crew (vai trò kỹ thuật theo `role_id` tương ứng) thành các dòng quan hệ movie–person–role.

Đầu ra

- ▶ 8 file CSV chuẩn hoá: `cast_info.csv`, `name.csv`, `title.csv`, `movie_keywords.csv`, `movie_companies.csv`, `company_name.csv`, `keyword.csv`, `role_type.csv`

Ghi chú kỹ thuật

- ▶ Các bản ghi có `movie_id` hoặc id không hợp lệ (không parse được sang số nguyên) sẽ bị loại bỏ và đếm số lượng cảnh báo (`skipped_movies`, `skipped_credits`) để theo dõi chất lượng dữ liệu đầu vào.
- ▶ `cast_info.csv` chỉ giữ lại các dòng có `movie_id` đã tồn tại trong `title.csv` — đảm bảo tính tham chiếu toàn vẹn (referential integrity) ngay từ giai đoạn transform.

3.3. Bước 3 — Lọc và Hợp nhất (normalize.py)

Sau khi có 8 bảng chuẩn hoá từ Bước 2, script `normalize.py` thực hiện 2 nhiệm vụ: (1) rút gọn `cast_info.csv` bằng cách join với `role_type.csv` để thay `role_id` bằng tên vai trò trực tiếp, và (2) hợp nhất từng bảng mới vào bảng tương ứng trong dataset gốc.

BƯỚC 3 · Rút gọn cấu trúc và hợp nhất vào dataset gốc

File thực thi: `normalize.py`

Mục tiêu

- ▶ Loại bỏ cột dư thừa (`role_id` sau khi đã join lấy tên vai trò), đồng thời gộp dữ liệu mới vào các bảng gốc của dataset chính (`companies`, `movies`, `cast`, `keyword`, `genre...`) mà không tạo trùng lặp.

Đầu vào

- ▶ 8 bảng đầu ra từ Bước 2 (đặt tại `scrape_data/output/`)
- ▶ Các bảng gốc của dataset chính (đặt tại `final_dataset/` và `data/`), ví dụ: `companies.csv`, `movies.csv`, `cast.csv`, `cast_movie.csv`, `keyword.csv`, `genre.csv`...

Xử lý chính

- ▶ Join `cast_info` ↔ `role_type` theo `role_id`, sau đó loại cột `role_id` để được `cast_movie_scrape.csv` chỉ chứa tên vai trò (`cast_role`) thay vì mã số.
- ▶ Với mỗi cặp bảng (gốc, mới): đọc cả hai bằng `pd.read_csv`, gộp bằng `pd.concat` theo hàng (`ignore_index=True`).
- ▶ Áp dụng `drop_duplicates()` trên toàn bộ tập đã gộp để loại các dòng trùng lặp hoàn toàn (xảy ra khi cùng một bản ghi xuất hiện ở cả 2 nguồn).
- ▶ Riêng bảng `movies`: trước khi gộp, chuyển cột `release` từ chuỗi ngày đầy đủ về dạng năm (`Int64`) để khớp định dạng cột `release` trong dataset gốc.
- ▶ Với `keyword` và `genre`: thực hiện remap ID — chuẩn hoá text (viết thường, trim khoảng trắng), xây dựng từ điển ID mới duy nhất cho toàn bộ tập từ khoá/thể loại hợp nhất, sau đó ánh xạ (merge) ID cũ sang ID mới cho cả hai nguồn dữ liệu trước khi gộp `movie_keyword` / `movie_genre`, tránh xung đột ID giữa 2 nguồn.

Đầu ra

- ▶ `final_dataset/companies.csv`, `movie_companies.csv`, `movies.csv`, `cast.csv`, `cast_movie.csv` — đã gộp và loại trùng.
- ▶ `keyword.csv`, `movie_keyword.csv` — đã remap ID đồng nhất và gộp.
- ▶ `genre.csv`, `movie_genre.csv` — đã remap ID đồng nhất và gộp.

Ghi chú kỹ thuật

- ▶ Việc remap ID cho `keyword/genre` là bước bắt buộc về logic: nếu chỉ concat trực tiếp mà không remap, cùng một `keyword_id` có thể trở đến 2 từ khoá khác nhau ở 2 nguồn, gây sai lệch dữ liệu (ID collision).
- ▶ `drop_duplicates()` chỉ phát hiện trùng lặp hoàn toàn theo giá trị; nếu cùng thực thể nhưng khác ID (như trường hợp `company/cast`), bước này chưa xử lý — cần lưu ý ở phần khuyến nghị cải tiến (Mục 4).

3.4. Bước 4 — Làm giàu dữ liệu / Cập nhật chỉ số (`add_rating.py`)

BƯỚC 4 · Bổ sung `vote_average` và `vote_count`

File thực thi: `add_rating.py`

Mục tiêu

- ▶ Bổ sung hai chỉ số đánh giá quan trọng (điểm trung bình và số lượng đánh giá) vào bảng `movies` đã hợp nhất ở Bước 3, phục vụ các truy vấn phân tích, xếp hạng, gợi ý phim.

Đầu vào

- ▶ movies.csv (kết quả hợp nhất từ Bước 3, đặt tại final_dataset/)
- ▶ tmdb_5000_movies.csv (dữ liệu thô gốc, chứa sẵn cột vote_average, vote_count)

Xử lý chính

- ▶ Thực hiện LEFT JOIN giữa movies và tmdb_5000_movies theo khoá movie_id, giữ nguyên toàn bộ các dòng phim hiện có trong movies.csv (how='left').
- ▶ Chuyển cột release về kiểu Int64 để đảm bảo tính nhất quán định dạng sau khi join.
- ▶ Áp dụng drop_duplicates() một lần nữa để loại các dòng trùng phát sinh do join (nếu có).

Đầu ra

- ▶ movies_with_votes.csv — bảng movies đầy đủ, có thêm 2 cột vote_average và vote_count.

Ghi chú kỹ thuật

- ▶ Vì dùng LEFT JOIN, các phim không có trong tmdb_5000_movies.csv (ví dụ phim thuộc dataset gốc ban đầu, không đến từ TMDB) sẽ nhận giá trị rỗng (NaN) ở 2 cột rating — cần xử lý giá trị thiếu trước khi đưa vào hệ quản trị CSDL.

4. Kết luận

Workflow hiện tại đáp ứng đúng mục tiêu đặt ra: thu thập dữ liệu phim mới từ TMDB API, chuẩn hoá về cấu trúc quan hệ tương thích với dataset gốc, hợp nhất an toàn (có xử lý trùng lặp và remap ID), và làm giàu thêm chỉ số đánh giá. Logic xử lý theo 4 bước tuần tự giúp dễ kiểm soát lỗi tại từng giai đoạn.